

Analiza Danych Podstawy Statystyczne (ADPS)

Laboratorium 4

Przykład 1 – analiza wariancji

- Wygeneruj 5 prób losowych z tego samego rozkładu normalnego o licznosciach 25:

```
n = 25; mi = 20; sigma = 1
```

```
y1 = rnorm(n, mi, sigma)
```

```
y2 = rnorm(n, mi, sigma)
```

```
y3 = rnorm(n, mi, sigma)
```

```
y4 = rnorm(n, mi, sigma)
```

```
y5 = rnorm(n, mi, sigma)
```

- Scal dane w ramkę i wyświetl wykresy pudełkowe:

```
y = cbind.data.frame(y1, y2, y3, y4, y5)
```

```
boxplot(y)
```

Przykład 1 – analiza wariancji

- Przygotuj dane na potrzeby funkcji `aov()`:
 `dane_anova = stack(y)`
 `names(dane_anova) <- c('dane', 'proba')`
- Sprawdź hipotezę o równości wariancji w próbach:
 `bartlett.test(dane~proba, data = dane_anova)`
- Przeprowadź analizę wariancji przy założeniu normalności rozkładów:
 `aov_res = aov(dane~proba, data = dane_anova)`
 `summary(aov_res)`

Przykład 1 – analiza wariancji

- Przeprowadź analizę wariancji bez założenia normalności rozkładów korzystając z testu Kruskala-Wallisa:

```
kruskal.test(dane~proba, dane_anova)
```

Przykład 1 – analiza wariancji

- Korzystając z metody Tukeya sprawdź, czy dla którejś z prób jej wartość średnia odbiega od wartości średnich w pozostałych próbach:

```
Tukey_res = TukeyHSD(aov_res)
print(Tukey_res)
plot(Tukey_res)
```

Przykład 1 – analiza wariancji

- Powtórz testy dla danych, w których nie ma równości wartości średnich w poszczególnych próbach:

$n = 25$; $\mu = 20$; $\sigma = 1$; $\alpha_2 = 1,2$ lub 4

$y_1 = \text{rnorm}(n, \mu, \sigma)$

$y_2 = \text{rnorm}(n, \mu, \sigma) + \alpha_2$

$y_3 = \text{rnorm}(n, \mu, \sigma)$

$y_4 = \text{rnorm}(n, \mu, \sigma)$

$y_5 = \text{rnorm}(n, \mu, \sigma)$

Przykład 1 – analiza wariancji

- Przygotowanie danych, gdy próby mają różne długości:

```
n = 25; mi = 20; sigma = 1; al_4 = -2
```

```
y1 = rnorm(n, mi, sigma)
```

```
y2 = rnorm(n+1, mi, sigma)
```

```
y3 = rnorm(n+2, mi, sigma)
```

```
y4 = rnorm(n+3, mi, sigma) + al_4
```

```
y5 = rnorm(n+4, mi, sigma)
```

```
dane_anova = data.frame( dane = c(y1, y2, y3, y4, y5),  
  proba = rep( c("y1", "y2", "y3", "y4", "y5"), times =  
    c(length(y1), length(y2), length(y3), length(y4), length(y5))) )
```

- Powtórz wcześniej przeprowadzane testy dot. analizy wariancji dla powyższych danych.

Przykład 2 – regresja liniowa

- Wygeneruj dane zgodnie z poniższymi komendami:

`n = 100; mi = 0; sigma = 2`

`x = rnorm(n, mi, sigma)`

`e = rnorm(n, 0, 1)`

`b0 = 1; b1 = 2`

`y = b1*x + b0 + e`

`plot(x, y)`

Przykład 2 – regresja liniowa

- Wyznacz parametry prostej regresji $y = b_1 \cdot x + b_0$ i współczynnik determinacji R^2 :

$$b1_est = (\text{mean}(x \cdot y) - \text{mean}(x) \cdot \text{mean}(y)) / (\text{mean}(x^2) - (\text{mean}(x))^2)$$

$$b0_est = \text{mean}(y) - b1_est \cdot \text{mean}(x)$$

$$y_est = b1_est \cdot x + b0_est$$

$$R2 = 1 - \text{sum}((y - y_est)^2) / \text{sum}((y - \text{mean}(y))^2)$$

- Naniesienie prostej regresji na rysunek:

$$\text{arg} = \text{c}(\text{min}(x), \text{max}(x))$$

$$\text{out} = b1_est \cdot \text{arg} + b0_est$$

$$\text{lines}(\text{arg}, \text{out}, \text{col} = 'red')$$

Przykład 2 – regresja liniowa

- To samo za pomocą funkcji lm:

```
lm_res = lm(y~x)
```

```
summary(lm_res)
```

```
arg = c(min(x), max(x))
```

```
out = coef(lm_res)[2]*arg + coef(lm_res)[1]
```

```
lines(arg, out, col = 'green')
```

Przykład 2 – regresja liniowa

- Wyznacz parametry prostej regresji $x = c1*y + c0$ i nanieś ją na wykres z danymi:

```
lm_res = lm(x~y)
```

```
summary(lm_res)
```

```
arg = c(min(y), max(y))
```

```
out = coef(lm_res)[2]*arg + coef(lm_res)[1]
```

```
lines(out, arg, col = 'blue')
```

Przykład 3 – regresja, przyp. wielowym.

- Wygeneruj dane zgodnie z poniższymi komendami:

```
n = 100
```

```
x0 = rep(1, n)
```

```
x1 = (1:n)/n
```

```
x2 = sin(1:n)
```

```
x3 = runif(n, -1, 1)
```

```
x = cbind(x0, x1, x2, x3)
```

```
b = c(1, -2, 3, -1)
```

```
e = rnorm(n, 0, 0.5)
```

```
y = x%*%b + e
```

- Narysuj zmienną y:

```
plot(y, type='l')
```

Przykład 3 – regresja, przyp. wielowym.

- Wyznacz parametry modelu korzystając z metody regresji liniowej:

```
lm_res = lm(y ~ 1 + x1 + x2 + x3)
```

```
summary(lm_res)
```

- Sprawdź jaki jest wynik wywołania linii:

```
lm_res = lm(y ~ x0 + x1 + x2 + x3 - 1)
```

```
summary(lm_res)
```

- Wartości estymat parametrów modelu można obliczyć w następujący sposób:

```
b_est = solve(t(x)%*%x)%*%t(x)%*%y
```